



Reconhecimento de pneumonia em imagens de raio X

Ana Carolina Gontijo Graça


anagraca@dcc.ufmg.br



O aprendizado de máquinas tem sido muito utilizado na área da saúde desde que se percebeu que era possível identificar doenças e condições a partir de padrões, sejam em imagens, códigos genéticos, resultados de exames e etc. O meu trabalho consiste em tentar criar uma rede neural convolucional que consiga a partir de um banco de dados de treinamento diferenciar em imagens de raio X torácicas pessoas com pneumonia e pessoas sem pneumonia.

O banco de dados utilizado consiste em 5.163 imagens de treino e 640 imagens de validação. Essas imagens foram redimensionadas para serem utilizadas no CNN. Todas as imagens foram reduzidas para caberem em um quadrado de 100 por 100 pixels, com bordas pretas se necessário para que as imagens internas mantenham suas proporções. A escolha das bordas pretas se deve ao fato de que a maioria das informações importantes das imagens está em branco, portanto espera-se que partes pretas na imagem influenciem menos no resultado.

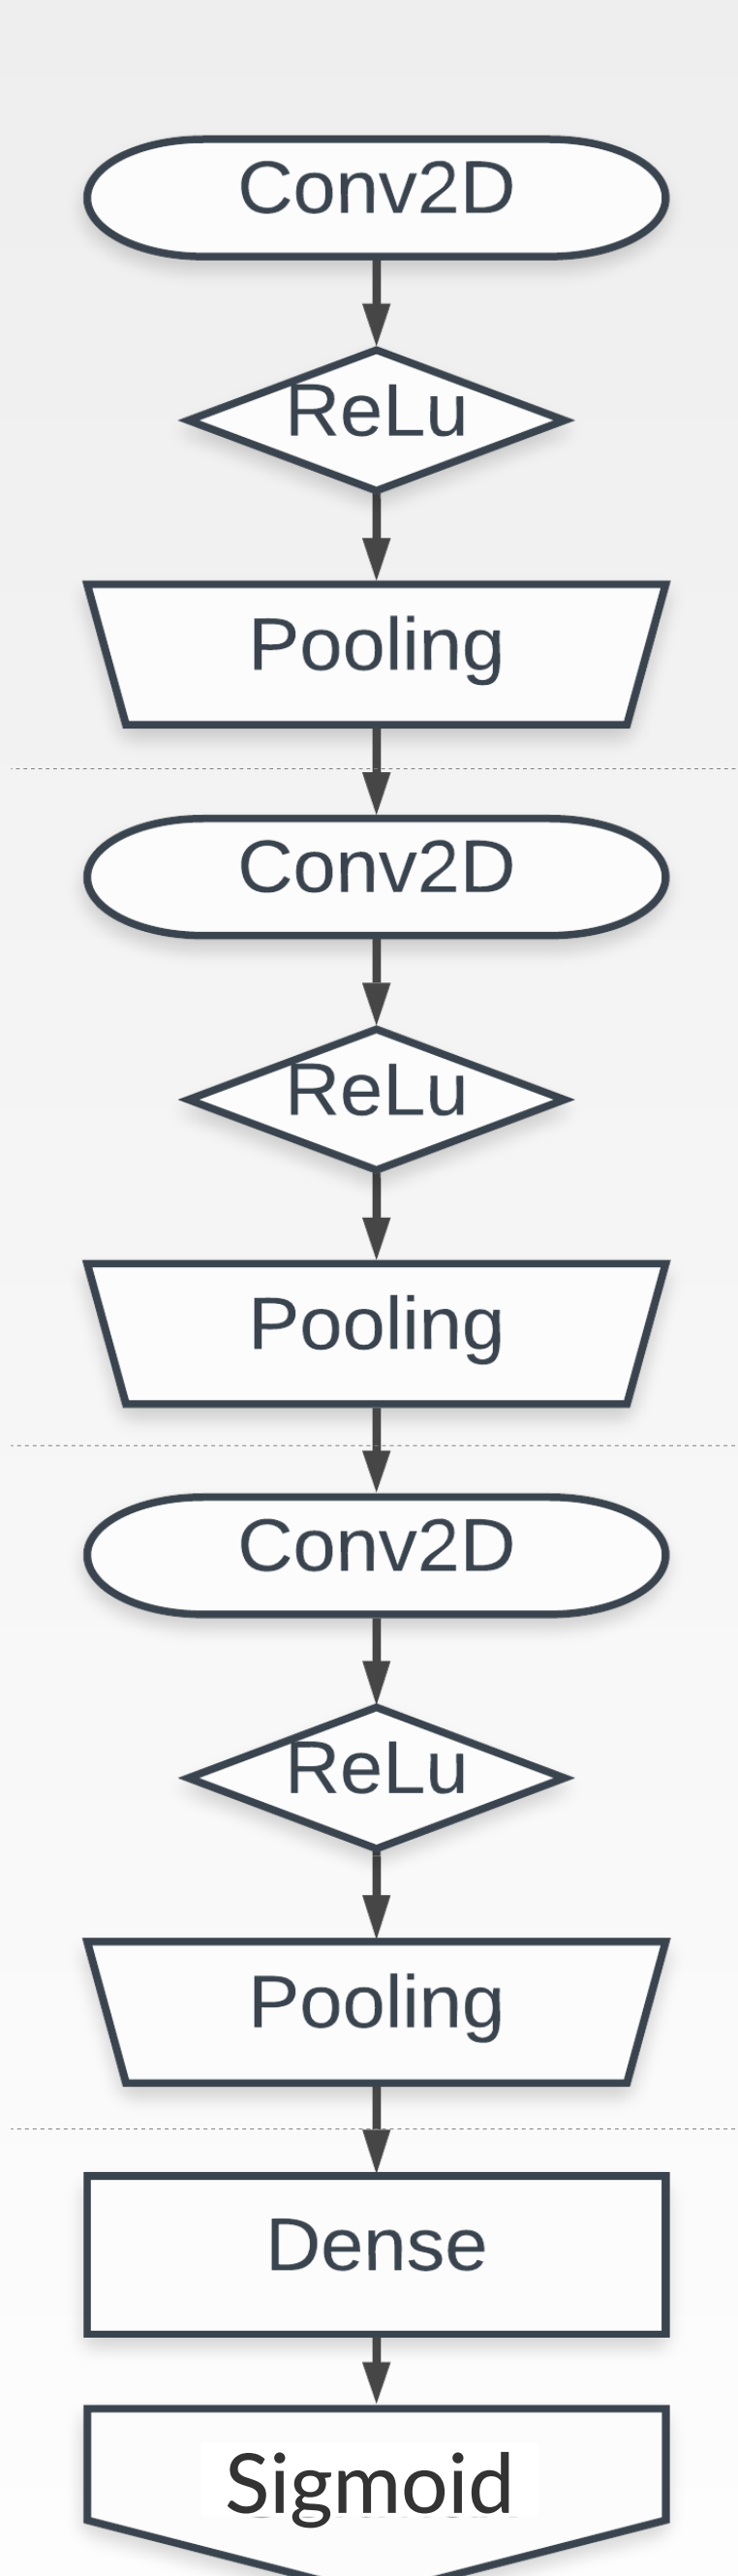
Imagens de raio X de pessoas sem pneumonia



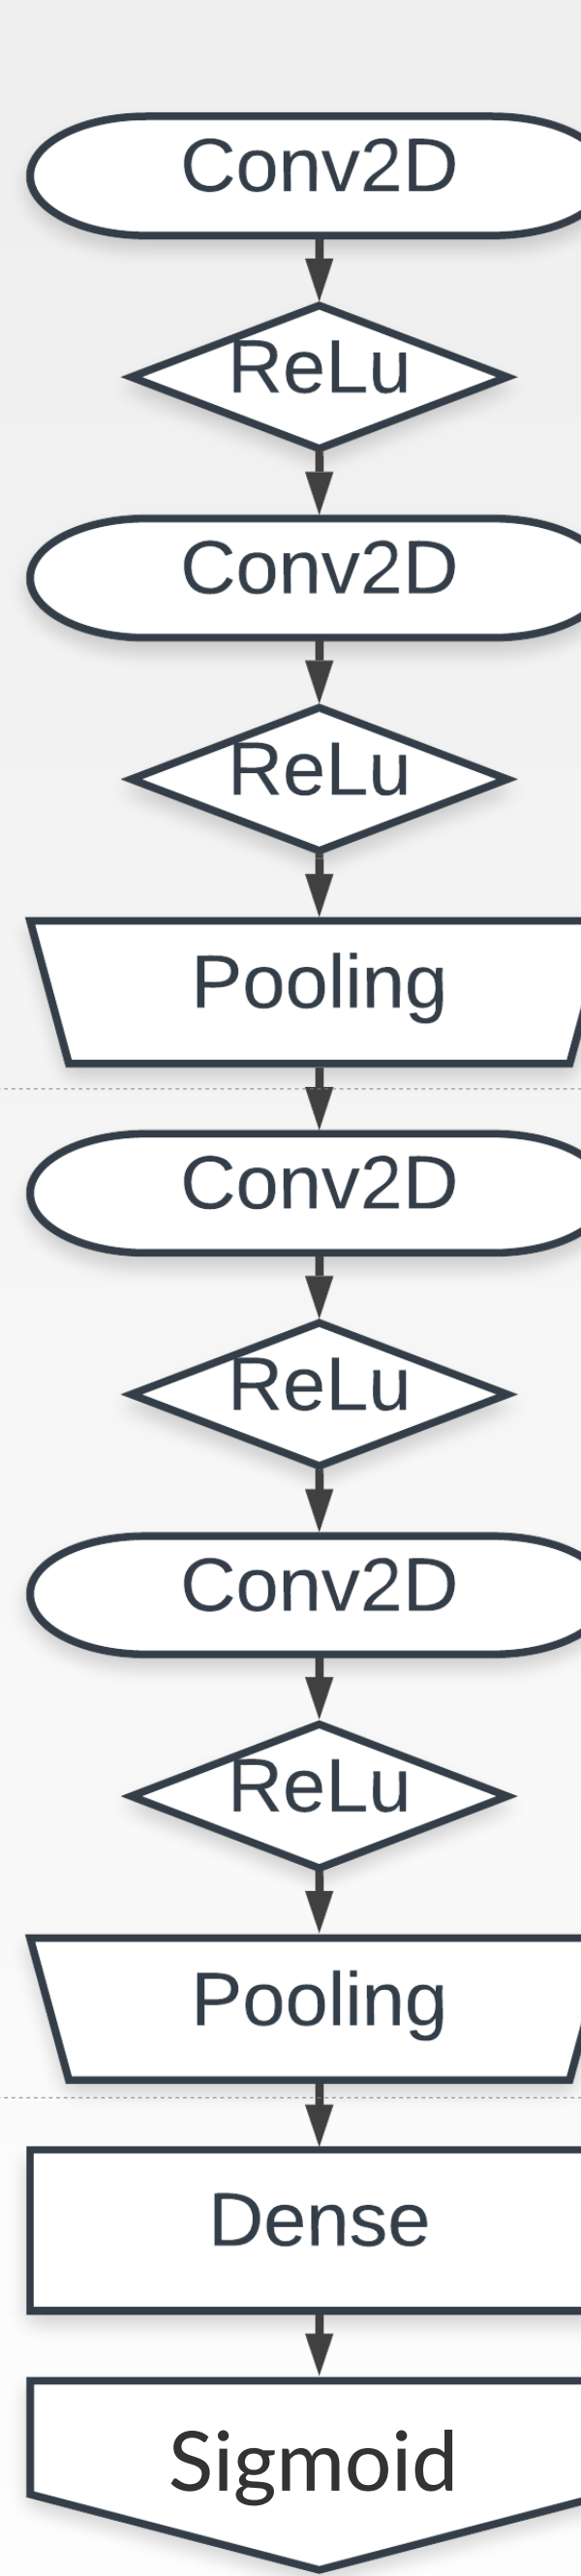
Imagens de raio X de pessoas com pneumonia



Foram testadas duas estruturas de redes neurais convolucionais (ou **CNNs**), a primeira consiste de 3 etapas de blocos de 2 camadas (convolução com *relu* e *pooling*) seguidas de uma camada *dense* e uma camada de *sigmoid dense* para finalizar a estrutura. A outra estrutura consiste de 2 etapas de blocos de 3 camadas (duas convoluções com *relu* e *pooling*) seguidas de uma camada *dense* e uma camada de *sigmoid dense*.

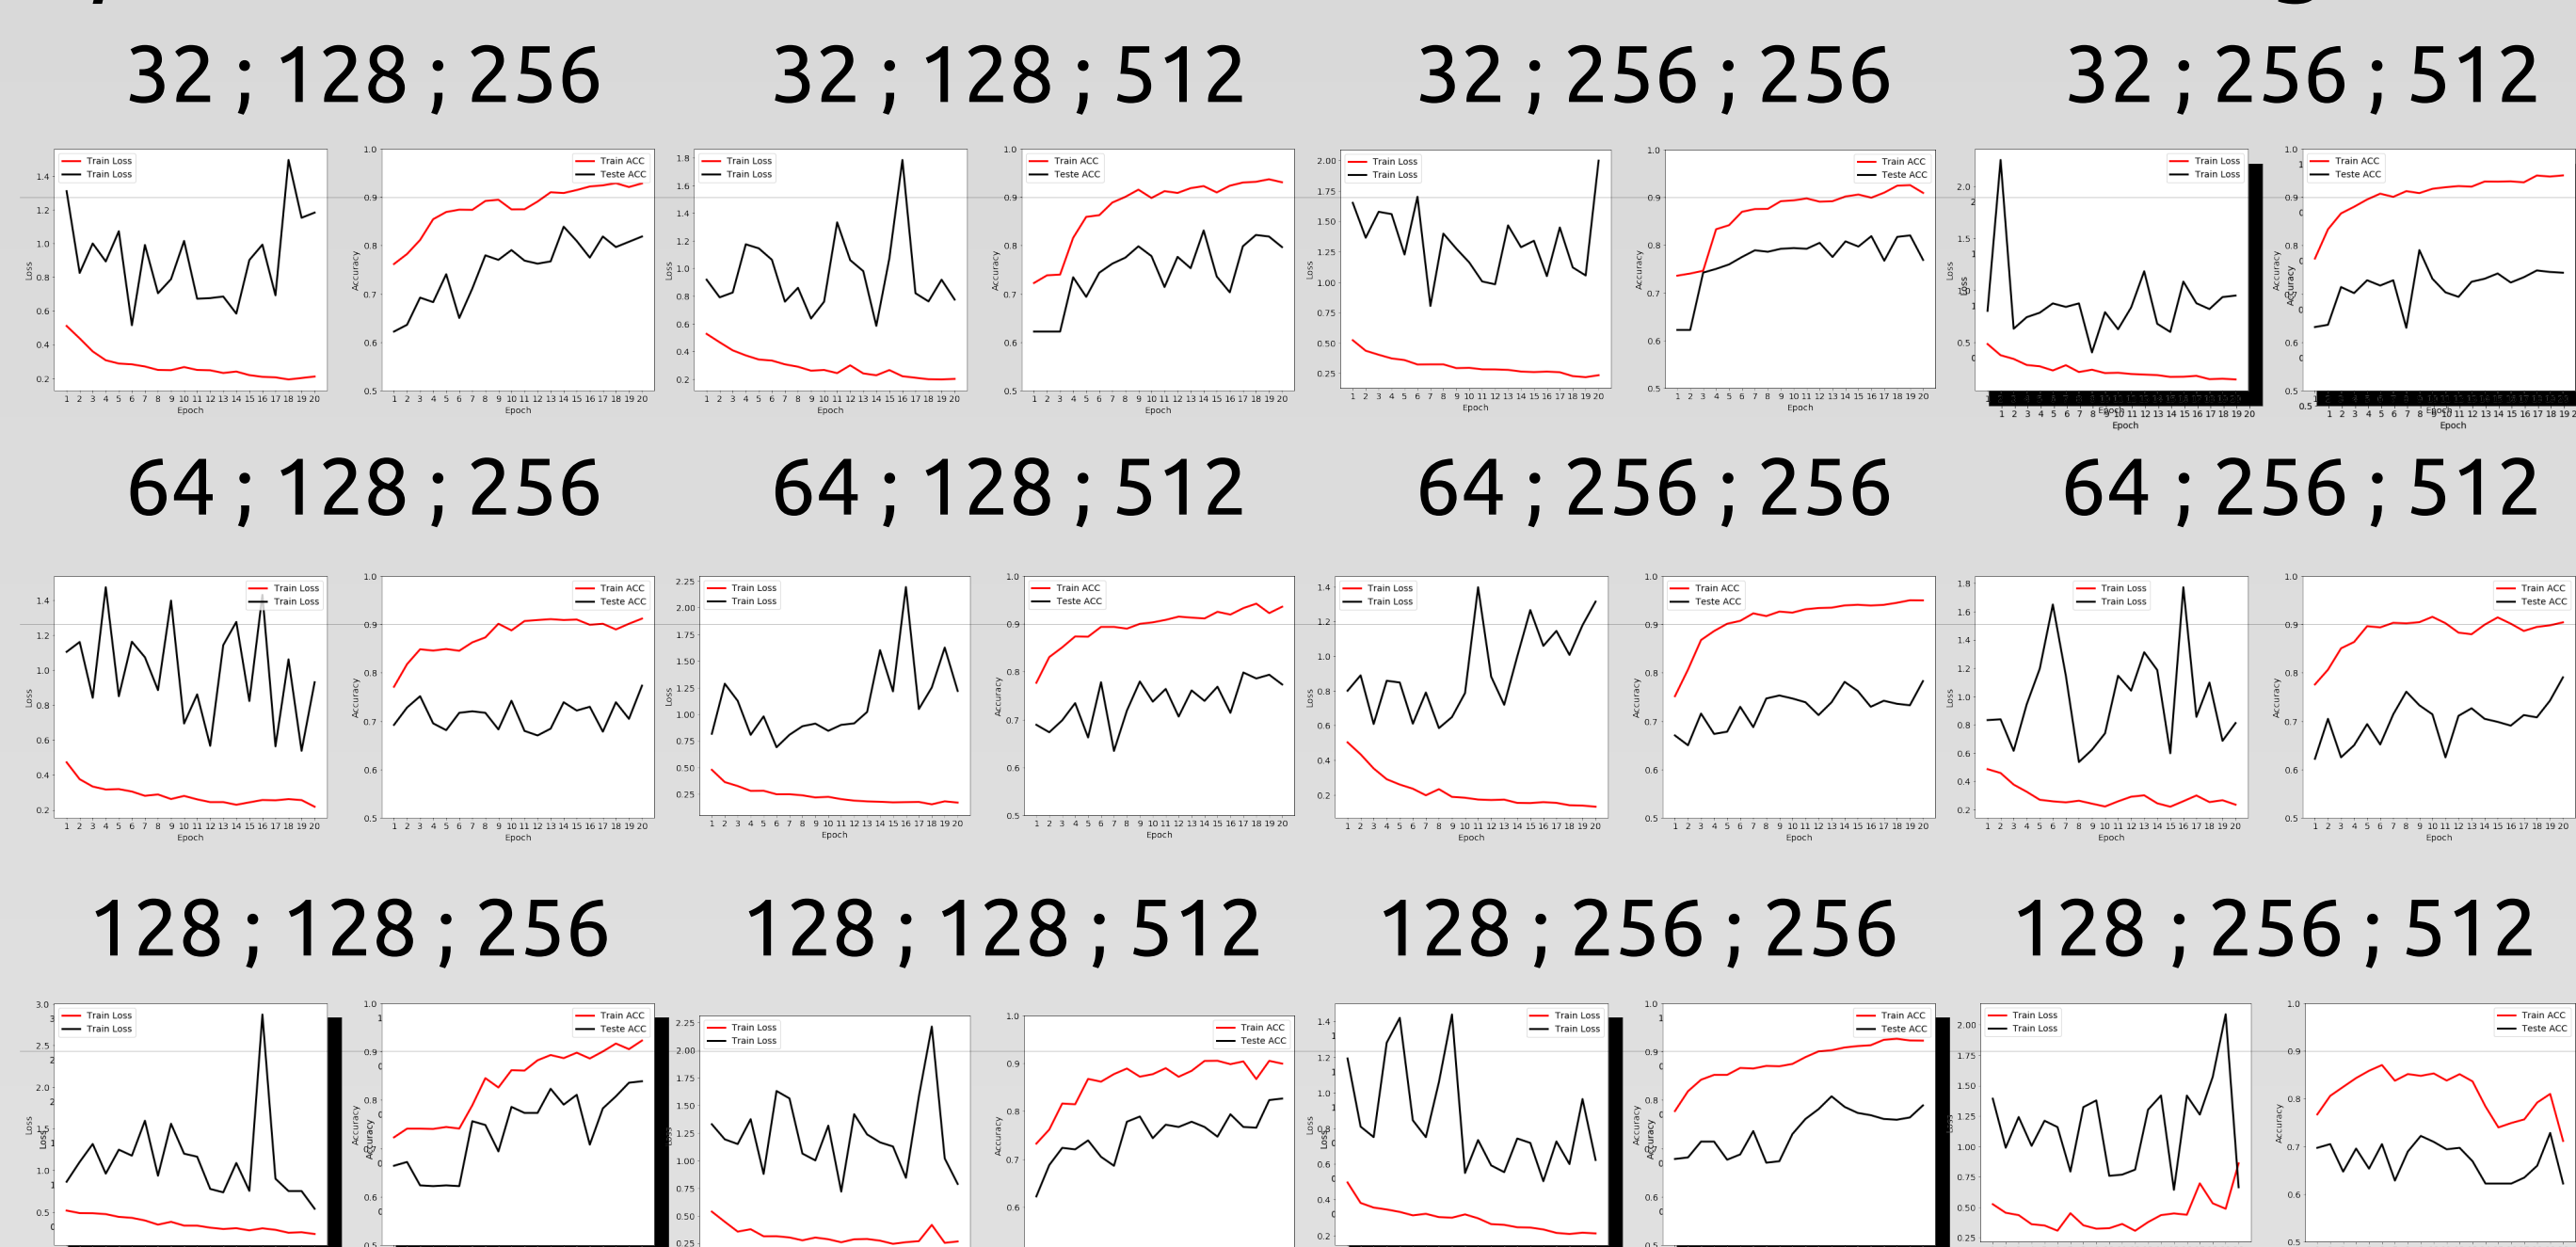


A **CNN** de tipo 1 é representada a esquerda e a de tipo 2 representada a direita. As etapas em cada uma são separadas por tracejados. Perceba que a **CNN** de tipo 2 contém mais camadas que a **CNN** de tipo 1, esta diferença deve impactar no resultado dos aprendizados. Cada camada de convolução tem o *dropout* definido aplicado sobre ela. As camadas *dense* podem conter mais de uma camada mas são todas após o *flatten*.

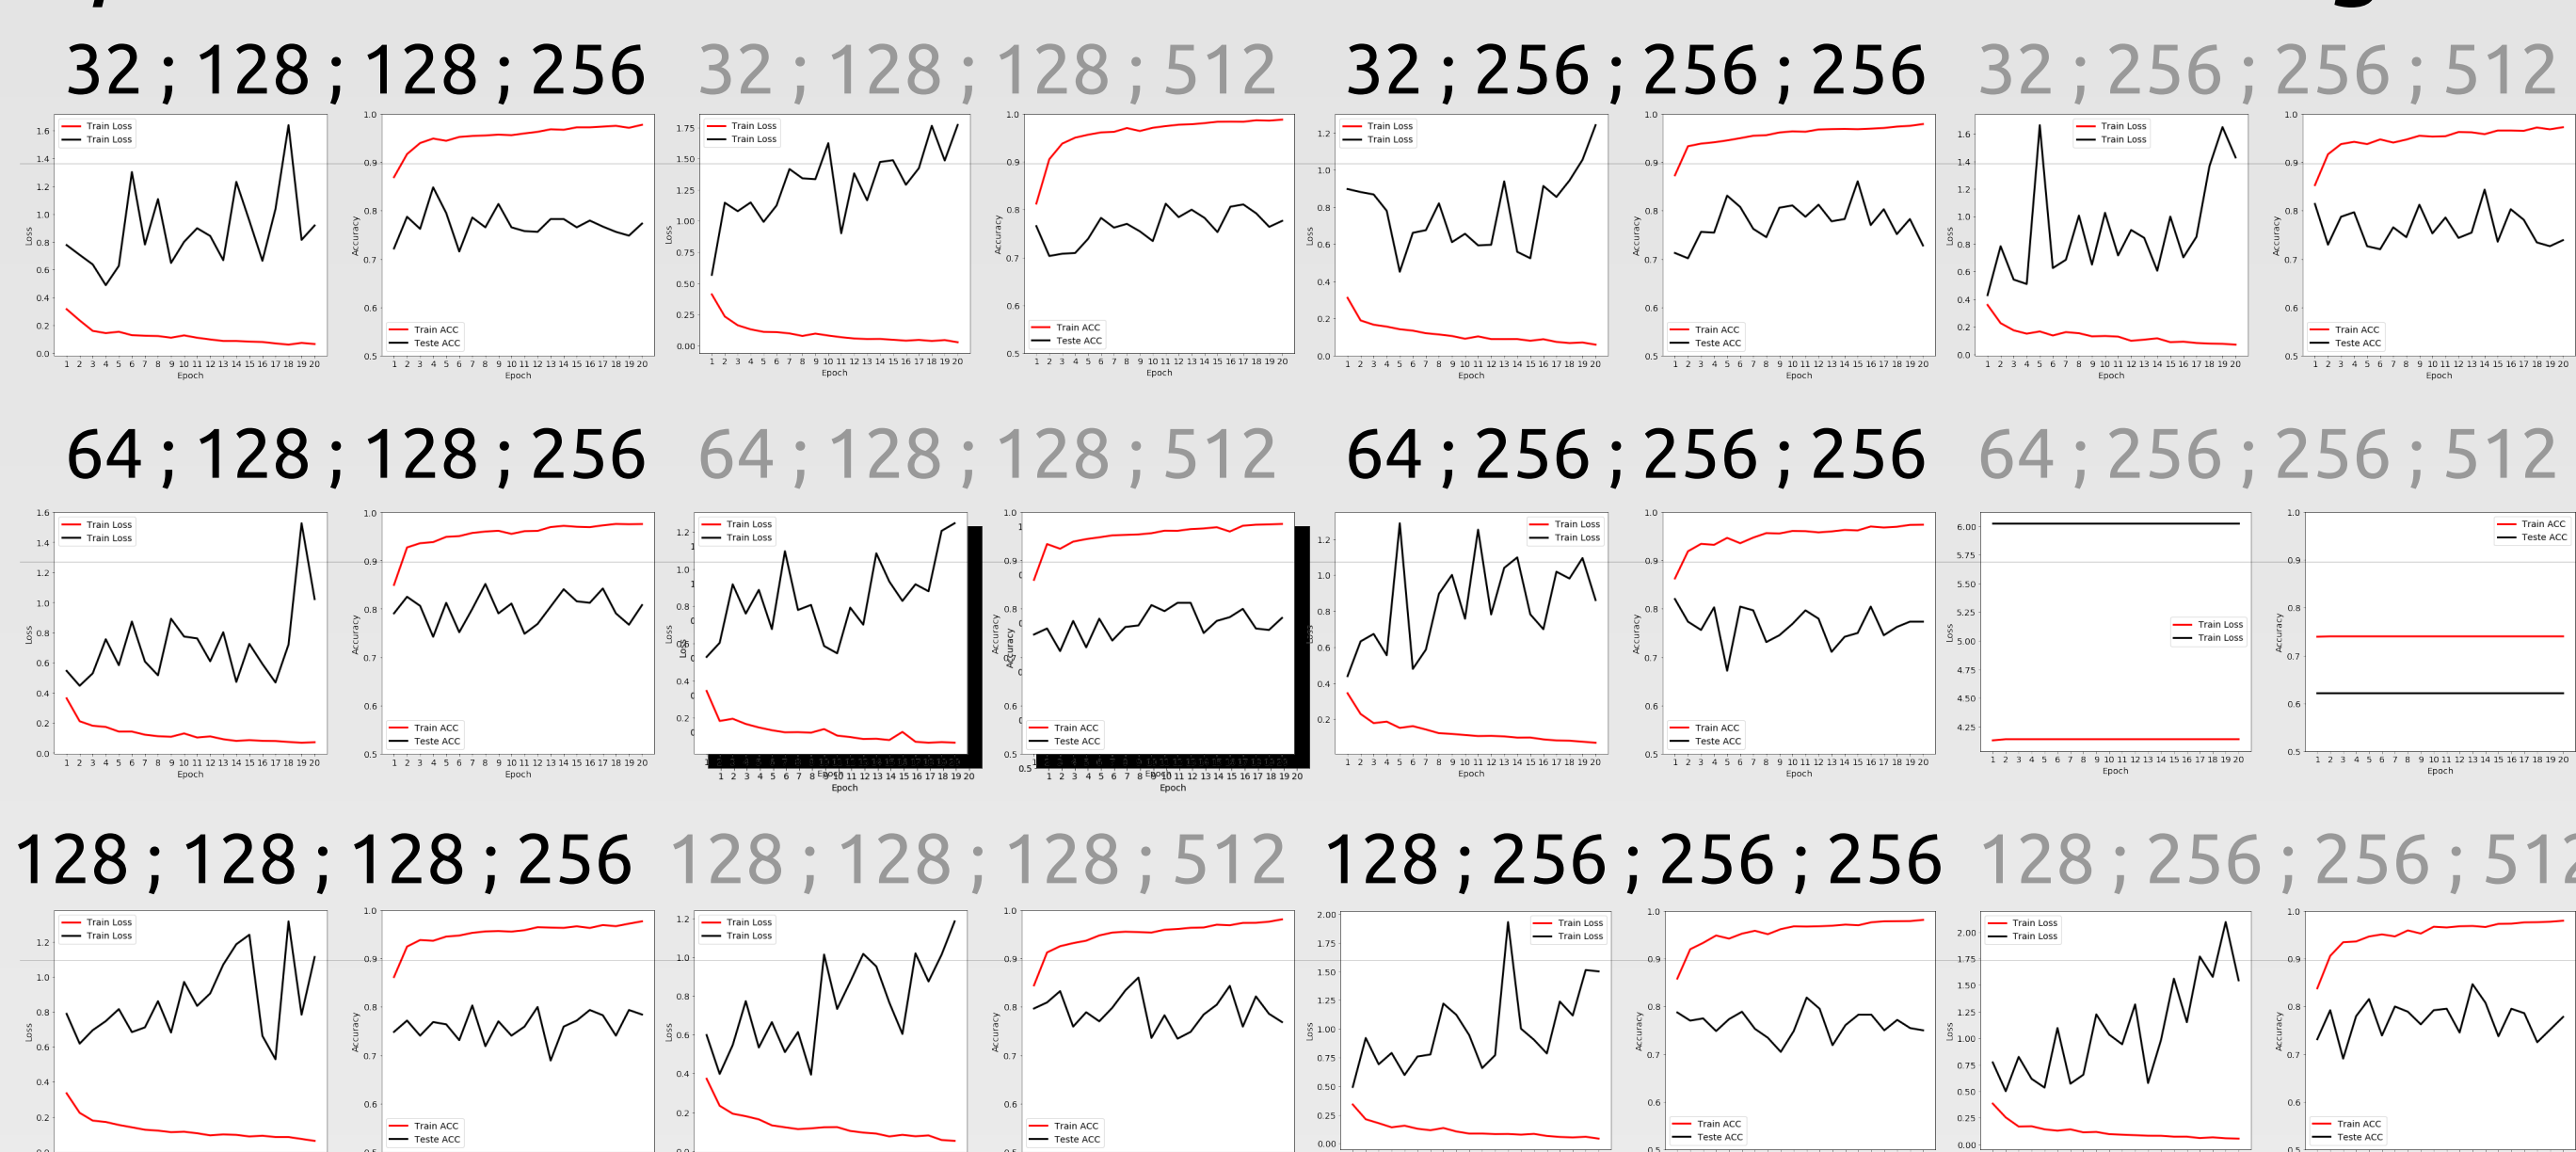


Foram realizados testes de parâmetros para as **CNNs**, e a partir das imagens a seguir foram definidos os melhores parâmetros para cada **CNN**, fixados a taxa de *dropout* em 50%, a taxa de aprendizado em 0.001 e as camadas *dense* de ambos os tipos de **CNN**.

Na **CNN** de tipo 1 foram variadas as quantidades de filtros de suas 3 camadas de convolução, estas quantidades e seus resultados com treinos de 20 *epochs* com *batches* de tamanho 8 são dados a seguir.



Na **CNN** de tipo 2 foram variadas as quantidades de filtros de suas 4 camadas de convolução, estas quantidades e seus resultados com treinos de 20 *epochs* com *batches* de tamanho 16 são dados a seguir.



Com os resultados obtidos é possível perceber que as melhores escolhas de parâmetros para as **CNNs** considerando estabilidade e valores de acurácia bons tanto para treino quanto para validação são:

•**CNN** tipo 1 :

•Números de filtros : 128 ; 128 ; 256

•**CNN** tipo 2 :

•Números de filtros : 64 ; 128 ; 128 ; 512

De toda forma é perceptível que os treinos da **CNN** do tipo 1 tiveram resultados muito superiores aos da **CNN** do tipo 2. Isso pode se dever a pouca quantidade de *epochs* para treinamento de muitos parâmetros.

Os treinos são instáveis independente da escolha de parâmetros testados acima. Isso se deve a natureza muito variável do problema, a pouca quantidade de base para treinamento e a variação de tamanhos das imagens, porém com melhoras nestes aspectos para estabilização da aprendizagem é possível desenvolver um software que determina a probabilidade de uma imagem de raio X conter indícios de pneumonia, auxiliando o laudo médico. Em casos em que o laudo aparentemente é de que a pessoa não tem pneumonia, caso o software retorne uma probabilidade alta de pneumonia este laudo poderia ser revisto, com mais exames por exemplo.

Supported by



FAPEMIG

